

# דו"ח מעבדה ת.ב 2

מור צדוק 314958026

אוריאל כהן 209087998

[https://github.com/MorTzadok/094295\\_hw2.git](https://github.com/MorTzadok/094295_hw2.git) - קישור לגיט

התרשמות ראשונית מהמשימה והדאטה

ראשית, כתבנו קוד קצר בקובץ `tests.py` שיבדוק כמה תמונות יש עבור כל ספרה רומית בנתיב שנספק לו – `train/val`. לאחר הרצה שלו על הדאטה המקורי שקיבלנו היה נראה שהנתונים יחסית מאוזנים אז זו דאגה אחת פחות. סכימת כל התמונות שקיבלנו מגיעה לכ- 2K תמונות, בשלב ראשוני זה העדפנו להתמקד על אגמנטציות שיגדילו את הדאטהסט.

שמנו לב שצויין בהוראות התרגיל שבדומה לדאטה סטים רבים, גם בדאטה סט שקיבלנו עלולות להיות טעויות בתיוג. מבחינת סדר הפעולות צריך קודם לטפל הדאטה שמתווייג לא נכון, אך מדובר בפעולה יותר מורכבת ולכן החלטנו להשאיר את ההתנסות בה להמשך.

החלטנו לחלק את מדגם האימון והולידציה ביחס של 20-80 - בד"כ רשת צורכת מספר רב של תמונות כדי לבצע למידה טובה ולכן לא נרצה לתת לה מעט מדי תמונות. בנוסף, מדובר ביחס נפוץ בשימוש לחלוקות מעין אלו.

על מנת שלא תהיה תמונה בסט הולידציה שהיא אוגמנטציה של תמונה באימון קודם חילקנו את הדאטה ולאחר מכן ביצענו אוגמנטציות על סט האימון בלבד. דרך פעולה זו נבעה מהסיכון שביצירת מצג שווה של תוצאות טובות - שאינן נבעו מלמידה טובה של המודל, אלא מהקשר בין התמונות מסט הולידציה וסט האימון.

## העשרה ראשונית של הדאטה – אגמנטציות

לאחר ההקצאה הרנדומית לסט אימון וולידציה, התחלנו במספר שינויים פשוטים: כדי לא לעשות מספר אגמנטציות באותה תמונה יצרנו מילון בו עבור כל מספר רומי יש רשימה שמכילה תמונות שלו לאחר אגמנטציה. לאחר שכל האגמנטציות בוצעו כל תמונה נשמרה בתקיה המתאימה לה בסט המבחן ע"י מעבר על הערכים במילון. שיטה זו וידאה שלא נעלה מספר שינויים באותה תמונה אלא שכל שינוי שנעשה על תמונה יצור תמונה חדשה שעברה אגמנטציה יחידה. בעינו זו שיטה מבוקרת יותר וכך אנו מודעים במדויק מה התוצאות של הפעולות שבצענו (אגמנטציות על אותה תמונה יכולות לבטל זו את זו או ליצור שינויים שלא חשבנו עליהם)

השינויים הראשונים כללו –


### • VERTICAL FLIP



השתמשנו באגמנטציה זו על כל ספרה שלא מכילה v מכיוון שגם לאחר האגמנטציה היא עדיין נשאת הספרה הזו


I, ii, iii, ix, x

### • HORIZONTAL FLIP



השתמשנו באגמנטציה זו על כל ספרה רומית שלא שני סוגי ספרות שונים, כך האגמנטציה משאירה אותה נראת כמו אותו המספר

I, ii, iii, v, x




### • ROTATE 180

השתמשנו באגמנטציה זו על כל ספרה רומית שתשאר יחסית דומה לעצמה לאחר שנהפוך אותה

I, ii, iii, x,

### • ROTATE X



ל x עשינו מקרה פרטי בו הוא מסתובב 90 וב 270 מעלות מכיוון שהוא עדיין נשאר x גם לאחר השינויים הללו, אך השינויים האלה לא זהים לקודמים,

בדקתי-



גב – ההדגמות בתרגיל זה מוקדשות לvs code ששעה את התרגיל הזה למהנה(התממשקות מעולה עם המכונה)

## סבב ריצה ראשון של המודל על הדאטה

הבהרה- כל עד לא יציין אחרת, תוצאות הריצות שדיווחנו הן לאחר עשרה אפוקים.

```
Epoch 10/10
-----
100%|
train Loss: 0.1616 Acc: 0.9523
100%|
val Loss: 0.6430 Acc: 0.8325

Training complete in 20m 8s
Best val Acc: 0.834928
```

בתוספת התמונות לאחר השינויים, מדגם האימון הגיע לגודל של כ 4500 תמונות, סט הולידציה לא שונה והיווה 20 אחוז מהדאטה המקורי – כ 400 תמונות. הרצנו את המודל על הדאטה שיצרנו ולאחר כמה ריצות(כי החלוקה לאימון וולידציה היא רנדומית) הגענו לתוצאות עקביות של דיוק סביב - 0.83-0.8 על הולידציה ו 0.9 על האימון. להלן דוג לאחת הריצות-

## הוספת אגמנטציות נוספות לדאטה

בשלב הזה הוספנו אגמנטציות נוספות-

### • FLIP & CHANGE NUMBER- VI <--> IV

הפעם זו אגמנטציה שלא משמרת את משמעות התמונה, אלא כזו שמעבירה אותה להיות ספרה אחרת - - כלומר כשאנחנו עושים horizontal flip לתמונות מהמחלקה של vi הן הופכות להיות iv ולהפך. השתמשנו בתכונה זו של הספרות הרומיות כדי להעשיר את הדאטה במחלקות הללו. כעת, גודל סט האימון עומד על כ 4500 תמונות בסט האימון, עשינו מספר הרצות לראות שהכל תקין והמשכנו להוסיף אגמנטציות.

### • Effect spread

את התמונות של אגמנטציה זו לא שמרנו במילון והוספנו בסוף התהליך כמו שעשינו עד עכשיו, אלא לאחר ששמרנו לתקיית הדאטה את התמונות עם האגמנטציות הקודמות עברנו על כל התקיה ושכפלנו את התמונות בה כשבשכול התמונה מופיע עם טשטוש. כך הגענו לכפ 9 אלף תמונות במדגם האימון. לפונק זו יש הייפר פרמטר ששולט בכמה פיקסל יכול להתרחק מהמקום המקורי שלו במהלך הטשטוש, עשינו כמה ניסויים על תמונות יחידות ובחרנו בפרמטר 10.

### • חשבנו להוסיף אגמנטציה של ZOOM אך נראה שמהבחינה הזו הדאטה מגוון מאוד.

## סבב ריצה שני של המודל על הדאטה

```
Epoch 10/10
-----
100%|██████████|
train Loss: 0.0574 Acc: 0.9815
100%|██████████|
val Loss: 0.8376 Acc: 0.8449
Training complete in 39m 57s
Best val Acc: 0.859189
```

המודל השתפר ונתן תוצאות של סביבות 0.86 על מדגם הולידציה. בשלב זה הרצנו ריצת לילה של כ 130 אפוקים לבדוק האם ההסתכלות לשנו על 10 אפוקים באמת מייצגת את היכולת של המודל לטווח הארוך. התוצאות הראו שכן, אמנם הדיוק על סט האימון היה כמעט מושלם אך הדיוק על סט הולידציה לא השתנה.

בנוסף, רצינו לבדוק שסט הולידציה מספיק גדול ומשקף, לכן הגדלנו את היחס בין סט הולידציה לאימון ליחס של 1\3 המודל החזיר תוצאות מעט פחות טובות אך בהפרש קטן של כ 2 אחוז שכנראה נובע מהקטנת מדגם האימון. מכיוון שכך, החלנו להשאר כרגע בחלוקה זו שנותנת לנו יותר ביטחון לגבי ולידיות של התוצאה. בנוסף, לא מדובר בביטחון שלנו בלבד אלא בהשפעה ישירה על המודל מכיוון שכפי שצויין בהוראות - המודל שנבחר הוא זה עם התוצאה הטובה ביותר על סט הולידציה.

## Label noise

לאחר שראינו תוצאות ואנחנו יותר מבינים את המשימה והדאטה ניגשנו לטפל בתיוגים הלא נכונים. כמובן שכדי לא ליצור אגמנטציות של תמונות שאינן מתויגות נכון נרצה קודם למחוק את התמונות הללו (או לתייג אותן למקום המתאים), ולכן נסיף את השלב הזה כקודם לכל מה שתארנו עד כה .

<https://towardsdatascience.com/an-introduction-to-classification-using-mislabeled-data-581a6c09f9f5>

לאחר קריאה באינטרנט(קישור לדוג מצורף כאן) ראינו שזו שיטה שלא תמיד עובדת ומכיוון שהדאטה שלנו לא גדול העדפנו למחוק בצורה ידנית את התיוגים הלא נכונים מאשר להסתכן באיבוד של דאטה המתוייג נכון:



- התמונות שלא זיהינו כספרה – מחקנו.

- תמונות שהיו נראות כמו ספרה שונה מהתיות העברנו לתקיית לספרה הנכונה.

- תמונות שהיו צריכות שינוי קל כמו 0x שהיה צריך שינוי קל של סיבוב לא-90 ביצענו ידנית.

לאחר סינון זה, נשארו עם דאטה בכמות של כ 2000 תמונות מהמדגם המקורי. ביצענו עליהם את האגמנטציות שתוארו והגענו לכ 7400 תמונות בסט האימון וכ 700 בולידציה. הרצה של הדאטה לאחר סינון תיוגים לא נכונים הביא לתוצאה של – 0.88 על מדגם הולידציה.

## ניסויים נוספים

שמנו לב שחלק מהתמונות של הספרה X מופיעות עם קו עליון ותחתון ואז כשמסובבים אותם ב90 מעלות ימינה\שמאלה מתקבלת תוצאה שלא כ"כ נראת כמו X. בדקנו מה תוצאות הריצות כשלא משתמשים באוגמנטציה זו על x וראינו שהתוצאות נשארו אותו דבר, ואף ירדו בכ2 אחוזים. זה הוביל אותנו לחשוב שאולי המודל לומד טוב יותר כשמקבל בסט האימון תמונות מסובבות של האובייקט ולכן ניסינו לסובב ב90 מעלות את כל המחלקות לא רק את X (חוץ מiv viii) -

מתקבל כ 11 אלף תמונות במדגם האימון לכן הקטנו את כמות התמונות שעוברות טשטוש, כך שכל תמונה רביעית לא תשוכפל עם גרסת טשטוש (במטרה לעמוד במקבלת התמונות). עבור ריצה הזו קיבלנו תוצאה פחות טובה ב2 אחוז אז בחרנו לא לבצע הזזה על כל תמונה, אלא לדלג על כל תמונה שלישית, ובכך השארנו מקום להוספה של אגמנטציות נוספות.

```
Epoch 10/10
-----
100%|
train Loss: 0.1626 Acc: 0.9434
100%|
val Loss: 0.5093 Acc: 0.8942

Training complete in 46m 37s
Best val Acc: 0.894188
```

בנוסף, צורפה אגמנטציה נוספת- שינוי בהירות כך שתמונה אחת מכל 4 משנה בהירות בעזרת משתנה רנדומי בטווח נתון.

## יצירת תמונות חדשות למחלקות קטנות

כשהוספנו תמונות לאחר אוגמנטציות שתליות במספר עצמו יצרנו דאטה פחות מאוזן.

לדוג, עבור חלוקת סט המבחן והולידציה של 1 ל 3 גודלי המחלקות הם-

באימון

במבחן


```
number of images in iii is : 58
number of images in ii is : 54
number of images in x is : 62
number of images in i is : 87
number of images in vii is : 63
number of images in v is : 63
number of images in vi is : 59
number of images in iv is : 90
number of images in viii is : 60
number of images in ix is : 75
671
```

```
number of images in iii is : 967
number of images in ii is : 883
number of images in x is : 1017
number of images in i is : 1433
number of images in vii is : 420
number of images in v is : 623
number of images in vi is : 490
number of images in iv is : 490
number of images in viii is : 395
number of images in ix is : 743
7461
```

ניתן לראות שיש פחות תמונות של המספרים viii .

כדי להוסיף ייצוגים נוספים שלהם שיסייעו למודל ללמוד אותם טוב יותר השתמשנו ביכולת מיזוג תמונות של PIL, את המיזוג עשינו כמובן לפני שאר האגמנטציות.

כדי לא ליצור תמונות מאוד לא ברורות נבחר את התמונות שאנחנו משלבים -נשים בתיקה נפרדת 10 מכל מחלקה- ii iii v והשילוש של התמונות יצור לנו תמונות חדשות המתאימות למחלקות i.vii.viii.



```
number of images in iii is : 967
number of images in ii is : 883
number of images in x is : 1017
number of images in i is : 1433
number of images in vii is : 753
number of images in v is : 623
number of images in vi is : 490
number of images in iv is : 490
number of images in viii is : 729
number of images in ix is : 743
8128
```

סט הולדציה כמובן לא השתנה משום שהחלטנו לא לעשות עליו מניפולציות. לעומת זאת, סט האימון השתנה -

נבדוק האם התוצאות השתפרו, ובמידה וכן נצור תמונות חדשות של iv vi בצורה דומה- קונקטנציה של v.i.

להפתעתנו, ביצועי המודל לא השתפרו אלא חזרו ל0.86 ולכן הסרנו את חלק הקוד האחראי על קונקטנציה. במקום זאת(מכיוון שיש שלנו עוד מקום במגבלת הדאטה) נוסיף עוד תמונות עם שינויי בהירות כך שכל תמונה שלא שונתה מבחינת רעש(שליש מהתמונות בתיקית האימון לאחר אגמנטציות) ישנה את הבהירות שלו.

```
number of images in iii is : 1160
number of images in ii is : 1060
number of images in x is : 1220
number of images in i is : 1720
number of images in vii is : 504
number of images in v is : 748
number of images in vi is : 588
number of images in iv is : 588
number of images in viii is : 474
number of images in ix is : 892
8954
```

כעת מס התמונות באימון הוא -

בריצה זו הדיוק הגיע ל0.86. שינינו את פרמטרי הבהירות וניסינו שוב וקיבלנו תוצאה דומה.

## הגדלת סט הולידציה

כדי שתוצאות הדיוק על מדגם הולידציה יהיו יותר מדוייקות נרצה להגדיל אותו ע"י אגמנטציות בדומב למה שעשינו במדגם האימון. השתמשנו באגמנטציות של  $vertical\ flip, add\ noise, vi \leftrightarrow iv$  כדי לא לתתמשקל גדול מדי לדאטה שעבר אגמנטציות קיצוניות יותר. לאחר התלבטות החלטנו לא לבצע העשרה זו לקוך הולידציה מחשש שנצור הטיה או שהדאטה לא יסקף מספרים אמיתיים אלא יותר אגמנטציות שלהם.

## הגשה סופית

לאחר שינויים וניסויים נוספים של פרמטרים וכו בקצה מה שבוצע: חלוקה של הדאטה ביחס של 1-3, סט הולדיציה מכיל 671 תמונות וסט האימון 9290 תמונות.

בוצעו אגמנטציות FLIP & CHANGE NUMBER- VI <--> IV I ROTATE 180 , VERTICAL\HORIZONTAL FLIP בפיו שחזאר בתחילת המסמך. ROTATE 90,270 בוצע על 2 שליש מתמונות כל המחלקות המחלקות חוץ מ iv ו vi. שמרנו את התמונות הללו לאחר האגמנטציה והוספנו רעש לרובן, כמעט כולן. ויתרנו על אגמנטציות שינוי הבהירות כי נראה שאגמנטציה הסיבוב שמולה בחנו את הבהירות נותנת תוצאות טובות יותר. תוצאות המודל על דאטה זה עבור 10 אפוקים של אימון הן –

```
val Loss: 0.4598 Acc: 0.9046
```

```
Epoch 10/10
```

```
-----
```

```
100%|
```

```
train Loss: 0.0232 Acc: 0.9936
```

```
100%|
```

```
val Loss: 0.5391 Acc: 0.8808
```

```
Training complete in 38m 11s
```

```
Best val Acc: 0.904620
```

להלן הגרפים של הלמידה-

